

Lista 1

2025-11-03

Pacotes necessários

Para essa lista de exercícios serão necessários os pacotes *data.table* e *dplyr*, para leitura e manipulação das bases de dados, respectivamente.

```
# instale os pacotes com os comando abaixo
# install.packages("tidyverse") # obs: o pacote dplyr faz parte do pacote tidyverse
# install.packages("data.table")

# apos a instalação, importe os pacotes
library(tidyverse)
library(data.table)
```

Exercicio 1 : Leitura dos dados

A função `fread` da biblioteca `data.table` é uma versão otimizada das funções `read.csv` e `read.csv2` para grandes bases de dados.

a) Leia novamente as bases de dados da CGIL de 2024 e 2025 utilizando a função `fread`. (Guarde cada uma das bases em uma variável)

Dica : Consulte o `help(fread)` para mais informações sobre a leitura.

```
dados_2024 <- fread("CGIL_CNIG_2024.csv", encoding="UTF-8")
dados_2025 <- fread("CGIL_CNIG_jan-set2025.csv", encoding="UTF-8")
```

b) Junte as duas bases de dados em uma só variável.

```
dados <- rbind(dados_2024, dados_2025)
```

Exercicio 2 : Limpeza e manipulação dos dados

O pacote `dplyr` é focado em manipulação de bases de dados. Apesar de ter um grande numero de funções, a maioria delas tem nomes intuitivos, por exemplo:

- `filter` : filtra as linhas de acordo com as condições dadas;
- `select` : seleciona as colunas indicadas;
- `group_by` : agrupa os dados de acordo com as colunas escolhidas;
- `count` : conta a quantidade de elementos na coluna;
- `summarise` : agrega os dados das colunas indicadas de acordo com as medidas escolhidas.

Esses comandos podem ser encadeados para recriar as tabelas vistas ao longo do curso, como por exemplo os dados filtrados

```
dados24 <- read.csv2("CGIL_CNIg_2024.csv", fileEncoding = "UTF-8")
dados25 <- read.csv2("CGIL_CNIg_jan-set2025.csv", fileEncoding = "UTF-8")
dados <- rbind(dados24, dados25)
```

```
dados_final <- dados %>%
  filter(modalidade == "CGIL", andamento == "DEFERIDO") %>%
  filter((ano == 2024 & mes == 9) | (ano == 2025 & mes %in% c(8,9)))
```

Ou, para replicar a tabela de frequência por gênero

```
dados_final %>%
  select(ano, mes, genero) %>%
  group_by(ano, mes, genero) %>%
  summarise(n = n(), .groups = "drop") %>%
  pivot_wider(names_from = c(mes, ano),
              names_prefix = "d_",
              values_from = n)
```

```
## # A tibble: 2 x 4
##   genero d_9_2024 d_8_2025 d_9_2025
##   <chr>      <int>      <int>      <int>
## 1 F          291         312         588
## 2 M          2298        3703        4084
```

```
países <- dados_final %>%
  select(ano, mes, pais) %>%
  group_by(ano, mes, pais) %>%
  summarise(n = n(), .groups = "drop") %>%
  pivot_wider(names_from = c(mes, ano),
              names_prefix = "d_",
              values_from = n)
```

a) Utilize as funções do pacote `dyplr` para recriar a tabela de frequência de países por mês e ano.

```
países <- países %>%
  mutate(total = d_9_2024 + d_8_2025 + d_9_2025)
```

b) A partir da tabela encontrada na letra a) crie uma nova coluna com o total de frequências ao longo dos anos.

```
países %>%
  arrange(desc(total)) %>%
  slice_head(n = 10)
```

c) Agora selecione os 10 países de maior frequência total. (Dica: `help(arange)`)

```
## # A tibble: 10 x 5
##   pais          d_9_2024 d_8_2025 d_9_2025 total
##   <chr>          <int>      <int>      <int> <int>
## 1 CHINA           695         1291        1158  3144
## 2 FILIPINAS        193          261         396   850
## 3 ESTADOS UNIDOS   181          227         212   620
## 4 ÍNDIA            151          124         309   584
```

##	5	ITÁLIA	111	126	309	546
##	6	GRÃ-BRETANHA	83	138	102	323
##	7	BANGLADESH	6	249	65	320
##	8	ALEMANHA	80	117	113	310
##	9	MÉXICO	58	126	109	293
##	10	FRANÇA	61	102	99	262